1 Laboratorium 4. Regresja liniowa.

Wczytaj do pakietu dane ze zbioru 'crime.txt'.

- 1. Dla każdej z $\binom{14}{2}$ par utworzonych ze zmiennych $Rate, \ldots, X$ wykonaj wykres rozrzutu (to polecenie można wykonać za pomocą jednej komendy).
- 2. Wyznacz macierz współczynników korelacji próbkowych Pearsona dla zmiennych $Rate, \ldots, X$ (to polecenie również można wykonać za pomocą jednej komendy).
- 3. Na podstawie tych dwóch analiz odpowiedz na następujące pytania:
 - (a) które ze zmiennych objaśniających Age, \ldots, X wydają się mieć najmocniejszy liniowy wpływ na zmienną objaśnianą Rate?
 - (b) czy pojawia się problem współliniowości, tzn. czy istnieje choć jedna para silnie ze sobą skorelowanych zmiennych objaśniających?
- 4. Skonstruuj model regresji liniowej opisujący zależność między zmienną Rate a trzynastoma zmiennymi objaśniającymi Age, \ldots, X . Wyznacz wartości współczynników determinacji R^2 i $adjR^2$.

Podaj **równanie regresji** opisujące zależność zmiennej *Rate* od zmiennych objaśniających występujących w tym modelu.

Oblicz prognozowaną przez ten model wartość współczynnika Rate, gdy zmienne objaśniające Age, \ldots, X mają wartość

- 5. Powtórz analizę z poprzedniego punktu, przyjmując za zmienne objaśniające:
 - (a) Ex1, X, Ed, Age, U2,
 - (b) EX0, LF, M, N, NW.
- 6. Spośród tych trzech modeli regresji liniowej wybierz "najlepszy", za kryterium wyboru przyjmując wartość **skorygowanego współczynnika determinacji**.

Podaj **równanie regresji** opisujące zależność zmiennej *Rate* od zmiennych objaśniających występujących w tym modelu.

- 7. Oblicz prognozowaną przez "najlepszy" model wartość współczynnika *Rate* dla podanych powyżej wartości zmiennych objaśniających. Porównaj obie prognozy.
- 8. Za pomocą wykresu kwantylowego dla rezyduów zbadaj (nieformalnie), czy spełnione jest założenie o normalności wektora błędów: $\boldsymbol{\varepsilon} \stackrel{D}{=} N(\mathbf{0}, \sigma^2 \boldsymbol{I}_n)$.